

Análisis de soluciones existentes

Context Rot en LLMs: revisión de literatura

Tomás Pablo Korenblit

Mayo 2026


Licenciatura en Ciencia de Datos · Ciencia de Datos · 1C2026

Docentes: Rodrigo Díaz, Agustín Moro, Florencia Piñeyrúa

Delimitación del problema

Context Rot: los LLM pierden adherencia a las instrucciones a medida que la conversación crece.

La explosión de la investigación en IA



Fuente: API arXiv, mayo 2026.

Cómo funciona un LLM

Un LLM predice el próximo token, dado todo el contexto anterior. Para eso usa un mecanismo de **atención**: decide a qué partes del contexto darle más peso al generar cada token.

La atención es un **recurso finito**. Se reparte entre todos los tokens del contexto.

Las instrucciones del system prompt compiten por atención con todo lo que crece después.

Año	Tokens
2023	16K
2024	128–200K
2025	200K
2026	1M

1M tokens $\approx$ 2.000 páginas.

Trayectoria de la literatura



El problema del olvido existe desde 1994. Los Transformers lo convierten en otro tipo de olvido. Recién en 2024–2025 el campo empieza a estudiarlo sistemáticamente en conversaciones largas.

La era pre-Transformers (1994–2016)

Bengio, Simard & Frasconi (1994)

Learning Long-Term Dependencies with Gradient Descent is Difficult

IEEE Trans. Neural Networks

Demostraron matemáticamente que las redes recurrentes vanilla **no pueden** aprender dependencias largas: los gradientes se desvanecen o explotan al propagarse hacia atrás.

El olvido en redes neuronales queda formalmente demostrado.

Hochreiter & Schmidhuber (1997)

Long Short-Term Memory

Neural Computation

Primera solución al problema de Bengio.

Compuertas (*input, forget, output*) que regulan qué información se mantiene a través del tiempo.

Dominó NLP durante 20 años.

La memoria explícita resuelve el olvido, pero la arquitectura es secuencial y difícil de escalar.

La era Transformers (2017–2022)

Vaswani et al. (2017)

Attention Is All You Need

NeurIPS

Reemplazan la recurrencia por atención pura. Permite paralelizar y escalar.

Base de todos los LLMs modernos.

Brown et al. (2020)

Language Models are Few-Shot Learners

NeurIPS

GPT-3, 175B parámetros.
Comportamiento *emergente*:
in-context learning, seguir instrucciones, razonar.

La escala demuestra capacidades nuevas.

Ouyang et al. (2022)

Training Language Models to Follow Instructions with Human Feedback

NeurIPS / InstructGPT

RLHF aplicado a GPT-3. La base técnica de ChatGPT (nov. 2022).

Los LLMs salen del laboratorio.

Por qué los Transformers no resolvieron el olvido

LSTM

Memoria explícita con compuertas. Mantiene información a largo plazo *por diseño*.

Costo: arquitectura secuencial. No escala bien.

Transformer

Atención global sobre el contexto. Paraleliza y escala a millones de tokens.

Costo: la atención es un *recurso finito* que se reparte entre todos los tokens. No hay memoria privilegiada.

Los Transformers escalaron sacrificando memoria explícita. La atención global se diluye cuando el contexto crece. **Eso es Context Rot.**

LLMs Get Lost in Multi-Turn Conversation (preprint arXiv, Microsoft + Salesforce)

Qué hicieron

Compararon el mismo modelo en dos escenarios: *single-turn fully-specified* (toda la información de una sola vez) vs *multi-turn sharded* (la misma tarea fragmentada en turnos). 15 modelos de 8 familias, 6 tareas de generación.

Qué encontraron

Caída promedio del **39%** entre single-turn y multi-turn. Pasa en **los 15 modelos**.

Detalle: la capacidad (*aptitude*) baja solo $\sim 16\%$. La **varianza sube 112%**. La aptitud cae poco; lo que explota es la inestabilidad.

La brecha que importa

Limitación (autores): simulación automática, solo inglés.

Para mi trabajo: **no desagregan por tipo de instrucción**. Este es el hueco que el proyecto final va a llenar.

Multi-IF: Benchmarking LLMs on Multi-turn and Multilingual Instruction Following

Qué hicieron

En cada turno agregan una instrucción nueva al contexto (sin remover las anteriores). 14 modelos, 8 idiomas, 4.501 conversaciones de 3 turnos.

Definen **Instruction Forgetting Ratio (IFR)**: % de instrucciones que el modelo cumplió antes pero deja de cumplir en turnos posteriores.

Qué encontraron

o1-preview: **87,7% → 70,7%** de turno 1 a turno 3 (promedio sobre 8 idiomas).


Las instrucciones están en el contexto, no desaparecen. Pero el modelo deja de aplicarlas a medida que se agregan nuevas.

Limitación (autores): las conversaciones reales son de 10+ turnos. Multi-IF solo cubre 3.

Lost in the Middle: How Language Models Use Long Contexts, TACL

Qué hicieron

Dos tareas: QA multi-documento y recuperación clave-valor sintética. En ambas, el ítem relevante se ubicó en distintas posiciones del contexto. 7 modelos.



Qué encontraron

Curva U asimétrica: el inicio se retiene mejor que el final, el medio peor que ambos. En multi-doc QA con 20 docs, GPT-3.5 cae de ~75% (inicio) a ~52% (medio).

El paper documenta el efecto pero **no mide atención**. La conexión con system prompts en posición 0 es extrapolación mía.

Limitación (autores): tareas de recuperación en inglés; ni instrucciones ni casos realistas.

A Closer Look at System Prompt Robustness (UC Berkeley)

Qué hicieron

Prueba de estrés “Monkey Island”: partieron de un system prompt real y agregaron de **1 a 20 guardrails**. Modelo y tarea fijos. 5 modelos vía API (familia GPT-4o, o3-mini, DeepSeek V3/R1).

Dato de contexto: en prompts reales del GPT Store hay un **promedio de 5.1 guardrails** por prompt. La producción ya opera cerca de la zona problemática.

Qué encontraron

Al pasar de 1 a 20 guardrails, la adherencia a cada uno **se aproxima a 0%** de forma uniforme entre modelos.

Saturación: las instrucciones compiten entre sí. Mecanismo distinto al de Liu: acá el problema es la **cantidad**, no la posición.

Inferencia mía: si más reglas degradan la adherencia, repetir el prompt entero (que multiplica reglas en contexto) probablemente la degrade también.

Anil et al. (2024, Anthropic)

Many-shot Jailbreaking

Evidencia empírica: la tasa de jailbreak aumenta de forma sistemática con el número de ejemplos previos en el contexto. Más largo $\Rightarrow$ más vulnerable.

Rivasseau (2025)

LLM Reinforcement in Context

Formalización teórica del problema: el ratio de tokens del system prompt sobre el contexto total tiende a 0 con el largo. Propone insertar “interrupciones” periódicas como mitigación (sin evaluación empírica).

Los guardrails son instrucciones como cualquier otra. Si decaen, el sistema falla silenciosamente: sin alarma, sin error visible.

Repetir el prompt (práctica común)

Sin paper formal. Es la práctica más común en sistemas en producción.

Qué se hace

Re-inyectar el system prompt completo al comienzo de cada turno. Todas las instrucciones, siempre, sin distinción.

Lo que sí se sabe

Costo: $N \times$ tokens por conversación.

Mu et al. (2025): con más reglas en el prompt, la adherencia a cada una baja. Repetir todo puede **empeorar** la situación.

Limitación de la literatura: nadie mide cuántos sistemas la usan ni cuánto ayuda o perjudica en conversaciones largas reales.

The Instruction Hierarchy: Training LLMs to Prioritize Privileged Instructions

Qué hicieron

Entrenaron GPT-3.5 Turbo (SFT + RLHF) para priorizar instrucciones según origen:

system > usuario > multimodal > tool outputs.

La jerarquía se aprende en el entrenamiento, no se impone en contexto.

Qué encontraron

+63% robustez frente a extracción del system prompt. +30% frente a jailbreaks.

Limitación (autores): regresiones en over-refusal — a veces rechaza consultas benignas.

Mi extensión: la jerarquía ordena *roles*, no instrucciones individuales. Dentro de un mismo rol, no aborda el decay temporal.

Prompt Repetition Improves Non-Reasoning LLMs

Qué hicieron

Duplican el prompt entero back-to-back:
<QUERY><QUERY>. 7 modelos (Gemini, GPT-4o, Claude, DeepSeek), 7 benchmarks.

Mecanismo propuesto: la atención causal impide que tokens iniciales atiendan a posteriores. Repetir permite una “segunda pasada”.

Qué encontraron

47 victorias y 0 derrotas sobre 70 combinaciones, en modelos no-razonadores. En modelos con chain-of-thought el efecto es nulo o leve.

Limitación: duplica los tokens de *entrada* (no la salida ni la latencia). Sigue siendo uniforme: duplica todo el prompt por igual, sin priorizar.

Drift No More? Context Equilibria in Multi-Turn LLM Interactions (Adobe Research + UIUC, preprint arXiv)

Qué hicieron

Injectaron recordatorios del objetivo en **turnos fijos $t = 4$ y $t = 7$** sobre conversaciones de 10 turnos (τ -Bench). Tres modelos como simuladores de usuario (Llama-3.1-8B, 70B, Qwen 2).

Formalizaron el drift como divergencia KL respecto a una política de referencia (GPT-4.1).

Qué encontraron

El drift se **estabiliza en un equilibrio finito**; no crece sin techo. Los recordatorios bajan ese equilibrio (Llama-8B: 20,4 $\rightarrow$ 17,6).

Limitación: calendario fijo, no adaptativo. No seleccionan qué instrucción reinyectar según historial de compliance.

Comparación de mitigaciones

Método	Idea	Costo	Limitación
Repetir prompt	Re-inyectar todo cada turno	$N \times$ input	Saturación (μ)
Wallace (2024)	Jerarquía de roles en training	Cero	Estática
Leviathan (2025)	<Q><Q> (duplicar)	$2 \times$ input	Uniforme
Dongre (2025)	Reminders fijos	$\sim 1.2 \times$	No adaptativo

Cuatro estrategias, cuatro costos, cuatro límites.
Todas **uniformes** sobre el conjunto de instrucciones.

Marco teórico y lo que falta

Zhang, Yang & Wang (2025)

LLM pequeños (Llama-8B, Mistral-7B, Gemma-2B) se comportan como *filtros bayesianos descontados* ($\gamma < 1$): el prior pierde peso frente a las observaciones recientes.

El paper no habla de instrucciones; el puente con compliance es mío. *Conecta con Laban: la varianza explota porque el posterior se vuelve inestable.*

Greenblatt et al. (ICML 2024): *AI Control* en runtime. Marco complementario; los protocolos que proponen quedan expuestos si decae cualquier instrucción en contexto.

El hueco que importa

- **Nadie midió si el decay varía según el tipo de instrucción.** Sin eso, todo refuerzo selectivo es injustificado.
- Anthropic, OpenAI, Google y Meta no publicaron investigación primaria sobre Context Rot.
- Las mitigaciones son uniformes porque *no tienen datos para discriminar.*

Orientación del proyecto final

Antes de armar un BKT selectivo había que verificar el supuesto: ¿realmente las instrucciones decaen distinto?

Estudio que hice:

- 28 conversaciones · 244 observaciones · 5 modelos
- Modelo logístico ordinal bayesiano, efectos jerárquicos por tipo de decisión
- **Resultado:** $\sigma_\beta = 2,11$ (intervalo de credibilidad del 94%: [1,06, 3,28]). La heterogeneidad existe.

Próximo paso: armar el BKT con presupuesto fijo de tokens y compararlo contra refuerzo uniforme.

Trabajo sometido a JAIIO 55. Se anuncia a fines de mayo. No es resultado validado por pares todavía.

Referencias

Bengio, Y., Simard & Frasconi (1994). *Learning Long-Term Dependencies with Gradient Descent is Difficult*. IEEE Trans. NN.

Hochreiter & Schmidhuber (1997). *Long Short-Term Memory*. Neural Computation.

Krizhevsky, Sutskever & Hinton (2012). *ImageNet Classification with Deep CNNs* (AlexNet). NeurIPS.

Vaswani et al. (2017). *Attention Is All You Need*. NeurIPS.

Brown et al. (2020). *Language Models are Few-Shot Learners* (GPT-3). NeurIPS.

Ouyang et al. (2022). *Training LMs to Follow Instructions with HF* (InstructGPT). NeurIPS.

Anil, C. et al. (2024). *Many-shot Jailbreaking*. Anthropic, NeurIPS.

Liu, N. F. et al. (2024). *Lost in the Middle*. TACL.

Wallace, E. et al. (2024). *The Instruction Hierarchy*. OpenAI.

Greenblatt, R. et al. (2024). *AI Control*. ICML.

Laban, P. et al. (2025). *LLMs Get Lost in Multi-Turn Conversation*. arXiv preprint.

Mu, N. et al. (2025). *A Closer Look at System Prompt Robustness*. UC Berkeley.

Zhang, Yang & Wang (2025). *LLMs as Discounted Bayesian Filters*.

Leviathan et al. (2025). *Prompt Repetition Improves Non-Reasoning LLMs*. Google.

Dongre, V. et al. (2025). *Drift No More?*. Adobe + UIUC, preprint arXiv.

Rivasseau, T. (2025). *LLM Reinforcement in Context*. arXiv.

Chroma Research (2025). *Context Rot*. Industria.