

Refuerzo Selectivo de Instrucciones: Tracking Bayesiano de Compliance para Mantenimiento de Guardrails en LLMs

Tomas Korenblit

Ciencia de Datos · 1C2026

Docentes: Agustín Moro, Rodrigo Díaz, Florencia Pineyrúa

Problema: Context Rot

Los LLMs dejan de seguir sus propias instrucciones a medida que la conversación se alarga. Chroma Research (2025) lo midió en 18 modelos frontera y el patrón se repite en todos: 39 % de caída en tareas multi-turn (Laban et al., 2025), accuracy que baja de 87.7 % a 70.7 % en solo 3 turnos (He et al., 2024), y adherencia que se acerca a cero conforme se agregan reglas al system prompt (Mu et al., 2025). Hasta 25K caracteres de *whitespace* (sin contenido semántico) causan degradación medible (Du et al., 2025).

Este mes Anthropic habilitó la ventana de contexto de 1M de tokens en Claude Opus 4.6 y Sonnet 4.6, sin costo adicional por contexto largo. Cuando Liu et al. escribieron *Lost in the Middle* en 2023, 16K era un contexto grande. Los mecanismos de degradación (dilución de atención, sesgo posicional) escalan con la longitud del contexto, no mejoran. El costo de re-inyectar todo el prompt cada turno a 1M tokens es mucho mayor que a 16K. Comparar los métodos actuales, diseñados para ventanas de 16K–128K, contra contextos de 1M sería en sí mismo una contribución interesante.

Mecanismos de degradación

1. Dilución de atención: softmax distribuye masa entre más tokens, cada uno recibe menos
2. Sesgo posicional: lo que está en el medio del contexto se pierde (la “curva U” de Liu et al.)
3. Olvido directo: ~20 % de instrucciones seguidas se abandonan en 3 turnos
4. Compromiso prematuro: si el modelo se equivoca temprano, no se recupera
5. Saturación: a más reglas en el prompt, menor adherencia global

Soluciones Actuales

Estrategia	Limitación
Repetir todo cada turno	Saturación de guardrails
Repetición naïve del prompt	2× costo en tokens (Google, 2025)
No hacer nada	39 % caída documentada
Re-inyectar al compactar	Ignora decay gradual entre compactaciones
Jerarquía de prioridad	No aborda decaimiento gradual (OpenAI, 2024)
Ninguno de estos enfoques decide <i>qué</i> reforzar ni <i>cuándo</i> .	

Gap de Investigación

Componente	¿Existe?
LLMs olvidan mediblemente ($\gamma < 1$)	Sí
Repetición del prompt ayuda empíricamente	Sí
Olvido modelable como filtro Bayesiano	Sí
BKT para compliance de LLMs	No
Re-inyección basada en incertidumbre	No
Curvas de olvido por tipo de instrucción	No
Refuerzo selectivo bajo presupuesto de tokens	No

Propuesta

La idea es mantener, para cada instrucción del system prompt, una estimación de qué tan probable es que el modelo la siga cumpliendo. Señales como “¿usó la herramienta correcta?” o “¿respetó el formato?” actualizan esa estimación turno a turno, y entre turnos la probabilidad decae naturalmente.

Formalmente, para cada instrucción i en el turno t :

$$P(C_i | \mathcal{O}_{1:t}) = \frac{P(\mathcal{O}_t | C_i) \cdot P(C_i | \mathcal{O}_{1:t-1})}{P(\mathcal{O}_t)}$$

donde C_i es compliance y $\gamma < 1$ controla el decaimiento entre turnos. Dado un presupuesto fijo de B tokens, se refuerzan solo las instrucciones con menor $P(C_i)$.

¿Por qué Bayesiano?

Un clasificador binario dice “cumple” o “no cumple”. El approach Bayesiano da una probabilidad continua, acepta priors sobre tasas de decaimiento por tipo de instrucción, y se actualiza con cada observación. Eso es lo que hace falta para decidir dónde gastar tokens de refuerzo cuando hay un presupuesto limitado.

Pregunta de Investigación

¿Tienen los distintos tipos de instrucciones tasas de decaimiento mediblemente distintas? Y si las tienen, ¿puede un tracker Bayesiano explotar esas diferencias para mantener compliance equivalente a menor costo de tokens?

Hay un ángulo de seguridad importante: si los guardrails de seguridad decaen más rápido que los de formato, los reminders uniformes están sub-invirtiéndose en lo que más importa.

Referencias Clave

Paper	Aporte
Liu et al., 2023	Lost in the Middle (curva U)
He et al., 2024	Multi-IF, Instruction Forgetting Ratio
Mu et al., 2025	Saturación de guardrails
Chroma, 2025	Context rot en 18 modelos frontera
Zhang & Yang, 2025	LLMs como filtros Bayesianos descontados
Google, 2025	Prompt repetition como baseline
Dongre et al., 2025	Drift acotado, reminders funcionan

Corpus completo: 19 papers (2023–2026). 14 de 2025+.