

55 JAIIO, ASAIID 2026

Not All Instructions Are Forgotten **Equal**

(No todas las instrucciones se olvidan igual)

Tomás Korenblit

Licenciatura en Ciencia de Datos, UNSAM

github.com/korentomas/not-all-instructions

EL PROBLEMA

Un agente recibe sus instrucciones una sola vez, y tienen que valer durante toda la corrida

Los agentes LLM corren cientos de turnos llamando herramientas sin que nadie revise cada paso, mientras que sus límites operativos y salvaguardas se declaran al principio de la sesión.

Cada instrucción queda enterrada bajo el output que se acumula después de ella y compite por atención contra todo lo que sigue.

EL PROBLEMA

La adherencia se degrada con el contexto, y el promedio no dice cuál instrucción cayó

La caída promedio documentada es del 39% en configuraciones multi-turno (Laban et al., 2025), porque la atención no se distribuye uniforme sobre la ventana.

Los estudios existentes reportan adherencia promedio sobre conjuntos de instrucciones, un número que no identifica cuál regla se perdió.

ESTE TRABAJO

Medimos la retención instrucción por instrucción, y resulta muy despareja

-2,4 a +5,4

rango del efecto de repetir, en log-odds

3 de 12

instrucciones se benefician de ser repetidas

8 de 12

ya se cumplen por defecto

MÉTODO

Sesiones de código de 25 turnos con 12 preferencias plantadas al pasar

turnos 0 a 19, se inyectan archivos del codebase (98K a 203K tokens)

20 a 25, prueba

▲ 6 tempranas (turnos 1 a 7)

▲ 6 tardías (14 a 19)

Cada preferencia se pide como un comentario casual del usuario, y el código generado en los turnos de prueba se puntúa con checkers determinísticos en una escala ordinal de 0 a 3. El baseline corre las mismas sesiones sin plantar nada.

MÉTODO

Una regresión logística ordenada estima un efecto por instrucción

$$score_i \sim \text{OrderedLogistic}(\eta_i, c)$$

el puntaje 0 a 3 es ordinal y cae según dónde queda η respecto de tres cortes ordenados $c_1 < c_2 < c_3$

$$\eta_i = \alpha_{d[i]} + \beta_{d[i]} \cdot told_i$$

α_d es lo que el modelo hace por defecto para la decisión d , mientras que β_d es cuánto cambia al decirla

$$\alpha_d \sim N(\mu_\alpha, \sigma_\alpha), \beta_d \sim N(\mu_\beta, \sigma_\beta)$$

las 12 instrucciones comparten información mediante partial pooling, que protege contra los pocos datos por celda


$$\mu_\beta \sim N(0, 1), \sigma_\beta \sim \text{Exp}(1)$$

priors débiles centrados en cero, sin dirección asumida para el efecto

244 observaciones, 28 conversaciones, 5 modelos, 3 codebases. σ_β mide cuánto varían las instrucciones entre sí, y su posterior da 2,1.


RESULTADOS

Los datos crudos ya muestran tres patrones distintos



RESULTADOS


Tres instrucciones se benefician de ser repetidas



testing parametrize pasa de no usarse nunca (baseline 0,00) a retenerse cuando se pide ($\beta = 5,4$)


RESULTADOS

Ocho ya se cumplen por defecto, así que repetirlas no cambia nada



RESULTADOS


Una empeora al repetirla, aunque sospechamos un artefacto de medición



el checker de dependencies no new cuenta como nuevo cualquier import, incluidos los ya presentes en el archivo

RESULTADOS

Repetir todas las instrucciones desperdicia tokens en 9 de 12



una ganancia baja no justifica descartar una regla de seguridad, solo ahorra repetición en preferencias ordinarias

RESULTADOS

Ni el modelo ni el codebase explican la variación

Los interceptos por modelo y por codebase concentran su posterior cerca de cero ($\sigma \approx 0,3$), de modo que la heterogeneidad vive en las instrucciones y no en quién ejecuta ni dónde.

La retención tampoco sube de 26B a 120B parámetros, así que la desigualdad no es capacidad disfrazada.

Con baseline de un solo modelo esto sostiene invarianza débil, no ausencia de efectos por modelo.

IMPLICACIÓN

Una salvaguarda es una instrucción más, y el promedio puede esconder su caída

Una preferencia de código y un guardrail son el mismo objeto, a saber una instrucción dicha una vez que compite por atención, por lo que la retención medida acá es un proxy de cómo aguantaría una salvaguarda declarada.

Como la seguridad es conjuntiva, el cumplimiento agregado puede verse alto mientras la única regla que importa ya cayó, y por eso un agente desplegado necesita monitoreo por instrucción.

CONCLUSIÓN

La retención es medible, despareja y accionable


- La heterogeneidad entre instrucciones es grande, con efectos de $-2,4$ a $+5,4$ log-odds y $\sigma_{\beta} = 2,1$.
- Solo 3 de 12 instrucciones pagan el refuerzo, mientras que una política uniforme gasta en las 12.
- El marco per-instrucción habilita monitoreo selectivo, con BKT como dirección natural.

`github.com/korentomas/not-all-instructions`

Gracias.


Backup

El modelo reproduce la distribución observada



cero divergencias, $\hat{R} \leq 1,01$, ESS mínimo 1311, medias 1,70 (baseline) y 2,16 (treatment)

Las 12 medias observadas caen dentro del intervalo predictivo del 90%



BACKUP, ESPECIFICACIÓN

Especificación completa del modelo

Ordered logit con cutpoints ordenados por incrementos positivos, efectos jerárquicos no centrados por tipo de decisión, y priors débilmente informativos en escala log-odds, a saber $\mu_\alpha \sim N(0, 1.5)$, $\mu_\beta \sim N(0, 1)$ centrado en cero, $\sigma \sim \text{Exp}(1)$.

PyMC con sampler nutpie (NUTS), 4 cadenas de 1000 draws tras 1000 de tuning. Prior y posterior predictive checks en el repo.

BACKUP, EL EFECTO NEGATIVO

Por qué leemos dependencias no new como artefacto

El checker cuenta cualquier sentencia import como nueva, incluidos los imports ya presentes que el modelo vuelve a mostrar al reescribir un archivo, de modo que el puntaje castiga una conducta que la instrucción no prohíbe.

La dirección negativa es creíble ($P(\beta < 0) = 0,98$) pero la magnitud queda abierta, y separar la negación del contenido (comparar "avoid new imports" con "use only existing imports") lo resolvería.

El trabajo de 2026 confirma la dirección con menor resolución

- Omission vs commission (arXiv 2604.20911) encuentra que las prohibiciones decaen del 73% al 33% mientras que los requerimientos se mantienen, con señales de auditoría que se ven sanas mientras la restricción ya falló.
- Governance Decay (2606.22528) muestra salvaguardas borradas silenciosamente al compactar contexto.
- Ambos miden a nivel de categoría; este trabajo, en cambio, estima un efecto por instrucción individual.

BACKUP, ROBUSTEZ

Los hallazgos sobreviven los chequeos de robustez

Bajo un refit solo-Qwen (baseline y treatment del mismo modelo) dos de los tres efectos positivos retienen su HDI sobre cero, y el ranking de refuerzo se mantiene estable.

Sensibilidad a priors y exclusión del sentinel –1 documentadas en el repo.